PRACTICA 1
ALMACÉNS E MINARÍA DE DATOS

Alex Baquero Domínguez

alex.baquero@rai.usc.es

INDICE

1. Importación dos datos do Censo de población e vivendas 2001 do IGE.

Antes de comenzar a facer nada, debemos instalar o postgresSQL. Para isto é necesario saber que ao longo desta práctica vamos a necesitar instalar o *cstore_fdw*:

- O *cstore_fdw* non é compatible con versions anteriores de PostgreSQL ou posteriores (requiere a versión de PostgreSQL de 9.3 a 12). De esta maneira, elexiremos o PostgreSQL12 para facer esta tarefa.
- O *cstore_fdw* non é compatible con Windows. De esta maneira, elexiremos o sistema operativo Ubuntu para facer esta tarefa.

Creamos a nosa futura base de datos que tendrá una táboa chamada Parroquias da seguinte maneira:

```
create table Parroquias(
    PRO int not null,
    CON int not null,
    CP int not null,
    PROVINCIA varchar(80) not null,
    CONCELLO varchar(80) not null,
    PARROQUIA varchar(80) not null,
    POBOACION_TOTAL int not null
    );
```

Descargamos os datos do Censo de poboacion e vivendas 2001 do IGE a través de este enlace:

http://www.ige.eu/igebdt/esqv.jsp?paxina=002001&c=-1&ruta=parroquias/parroquias.jsp

Estos datos están almacenados nun archivo de Excel, o cal hai que transformar a formato *.csv* para poder copiar todos estos datos na nosa base de datos creada. Este hai que modifcalo para que este codificado a través de UTF-8 e eliminar o separador dos millares (os datos da poboacion serán números enteiros). Importamos os datos do .csv a través:

```
COPY Parroquias(PRO,CON,CP,PROVINCIA,CONCELLO,PARROQUIA,POBOACION_TOTAL)
from '/tmp/PARROQUIAS.csv' delimiter ';' csv header;
```

2. Cales son as 4 parroquias con máis habitantes da provincia de Pontevedra?

Seleccionamos as parroquias as cales teñan o carácter PONTEVEDRA na columna provincia e seleccionamos as primeiras catro filas, é dicir, as catro parroquias con mais poboacion.

```
SELECT parroquia, poboacion_total
from Parroquias
where provincia = 'PONTEVEDRA' order by poboacion_total desc fetch first 4 rows only
```

	parroquia character varying (80)	poboacion_total integer
1	VIGO	198212
2	PONTEVEDRA	52641
3	LAVADORES (SANTA CRISTI...	15965
4	MARÍN (SANTA MARÍA DO P...	15747

3. Mostra, para cada provincia, os municipios coa poboación superior a 15000 habitantes.

Facemos unha subconsulta que sume a poboacion das provincias para cada concello e para obter únicamente unha só fila por concello, agrupamos os datos por provincias e concellos.

Unha vez que temos a poboacion total por concellos a través da subconsulta, escollemos os concellos que teñan unha poboacion total superior a 15000 habitantes.

```
SELECT provincia, concello, p_t
FROM
(
    SELECT provincia, concello, sum(poboacion_total) as p_t
    from parroquias
    group by  concello, provincia
)
as s where p_t>15000
order by p_t asc
```

	provincia character varying (80)	concello character varying (80)	p_t bigint
1	LUGO	VIVEIRO	15240
2	LUGO	VILALBA	15365
3	A CORUÑA	TEO	15476
4	PONTEVEDRA	PORRIÑO, O	15960
5	PONTEVEDRA	TUI	16042
6	PONTEVEDRA	SANXENXO	16098
7	PONTEVEDRA	NIGRÁN	16110
8	A CORUÑA	BOIRO	17748
9	PONTEVEDRA	MOAÑA	17887
10	A CORUÑA	AMES	18782
11	PONTEVEDRA	PONTEAREAS	19011
12	LUGO	MONFORTE DE LEMOD	19091
13	A CORUÑA	CAMBRE	19262
14	PONTEVEDRA	LALÍN	19869
15	PONTEVEDRA	ESTRADA, A	22308
16	A CORUÑA	CULLEREDO	22348
17	A CORUÑA	ARTEIXO	23306
18	PONTEVEDRA	CANGAS	23981
19	PONTEVEDRA	MARÍN	24997
20	A CORUÑA	RIBEIRA	26086
21	A CORUÑA	OLEIROS	27252
22	A CORUÑA	CARBALLO	28142
23	PONTEVEDRA	REDONDELA	29003
24	A CORUÑA	NARÓN	32204
25	PONTEVEDRA	VILAGARCÍA DE AROUSA	33496
26	PONTEVEDRA	PONTEVEDRA	74942
27	A CORUÑA	FERROL	77950
28	LUGO	LUGO	88414
29	A CORUÑA	SANTIAGO DE COMPOSTELA	90188
30	OURENSE	OURENSE	107510
31	A CORUÑA	CORUÑA, A	236379
32	PONTEVEDRA	VIGO	280186

4. Instalación do *cstore_fdw*.

Cstore_fdw é unha extensión de almacén de columnas de código aberto que reduce o espazo de almacenamento de datos e as E/S de disco para bases de datos PostgreSQL.

Antes de comezar coa instalación do *cstore_fdw*, debemos instalar uns paquetes xa que este depende de protobuf-c para serializar y deserializar os metadatos da táboa:

```
Sudo apt-get install protobuf-c-compiler
Sudo apt-get install libprotobuf-c-dev
```

Instalamos o *cstore_fdw* a través de este comando:

```
Sudo apt-get update
Sudo apt-get install postgresql-12-cstore-fdw
```

Antes de usar *cstore_fdw*, agregamos `shared_preload_libraries` e `postgresql.conf` reiniciamos o postgres:

```
shared_preload_libraries = 'cstore_fdw'
```

Entramos en postgres por liña de comando: `sudo –i –u postgres`

```
psql
```

Creamos una táboa e reiniciamos o servidor:

```
CREATE FOREING TABLE parroquias_foreign
Sudo systemctl restart postgresql
```

Finalmente corremos `ALTER EXTENSION cstore_fdw UPDATE` e iniciamos sesión en Postgres de novo. Executamos os seguintes comandos para crear una táboa foránea de almacenamento de columnas:

1. Cargar a extensión por primeira vez despois da instalación:

```
CREATE EXTENSION cstore_fdw;
```

2. Crear un obxeto servidor:

```
CREATE SERVER cstore_server FOREIGN DATA WRAPPER cstore_fdw;
```

3. Crear táboa foránea

```
CREATE FOREIGN TABLE parroquias_foreign
(
    PRO INT,
    CON INT,
```

```
    CP INT,
    PROVINCIA TEXT,
    CONCELLO TEXT,
     PARROQUIA TEXT,
   POBOACION_TOTAL INT
)
SERVER cstore_server;
```

A continuación, cargamos datos na táboa:

```
\COPY parroquias_foreign FROM '/tmp/PARROQUIAS.CSV 'WITH CSV;
```

Mencionar que neste paso deron bastantes erros e tivemos que modifcar algunhas cousas do .csv como suprimir o título de cada columna, sustituir ; por un , e poner os todos textos entre comillas.

Procedemos a comparar o tamaño das táboas parroquias (táboa orixinal) e parroquias_foreign (táboa foránea). Para iso, executamos `\d+` para observar o tamaño das táboas:

Podemos ver que a táboa estranxeira ocupa menos que táboa orixinal. Observamos que a FDW pode traer ventaxas e ser moi útil, sobre todo nos casos en que se realice análise de datos:

- Compresión: reduce significativamente o espazo en disco e a memoria.
- Proxección de columnas: só le as columnas necesarias para a consulta.

Dende logo, en ocasións, pode evitar moitos contratempos. Xa que implementa un mecanismo de almacenamento en columnas e utiliza o formato Optimized Row Columnar (ORC). Por suposto, estas vantaxes teñen un custo, xa que seguramente a carga é un pouco lenta porque ten que comprimir a información.

5. Consultas sobre ambas táboas e observación sobre os tempos.

Faremos unha consulta complexa onde existan cálculos con funcions de agregados e veremos o plan de execución e o tempo:

```
explain analyze select concello, min(cp), avg(poboacion_total)
        from parroquias_foreign group by concello;
```

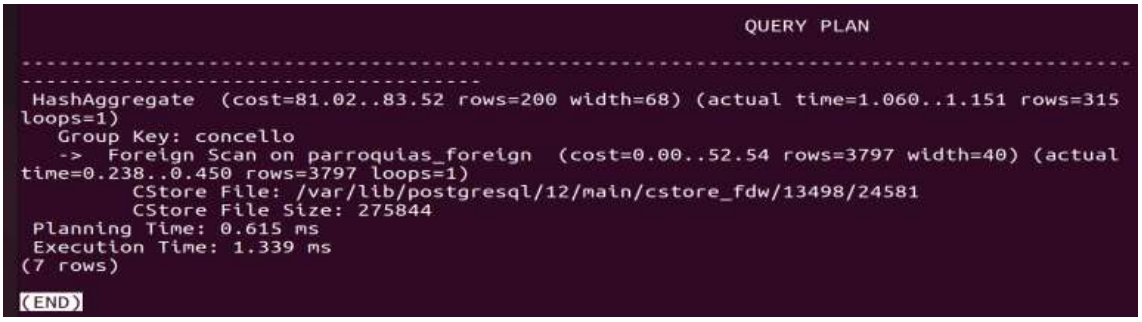

Se executamos a mesma consulta na táboa orixinal:

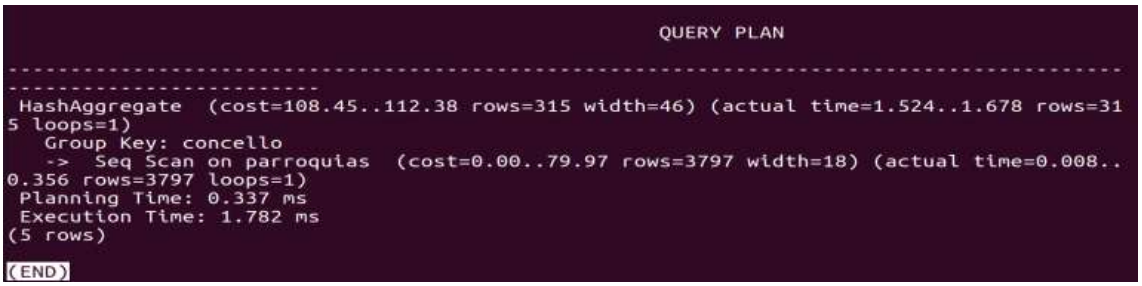

Se lle agregamos algún filtro á consulta:

```
explain analyze select concello, min(cp), avg(poboacion_total)
 from parroquias_foreign WHERE poboacion_total<10000 group by
                        concello;
```

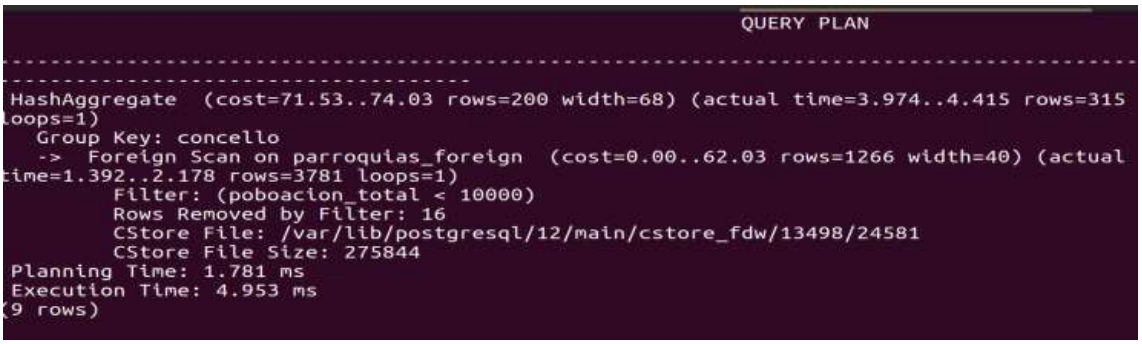

Para a táboa orixinal é:

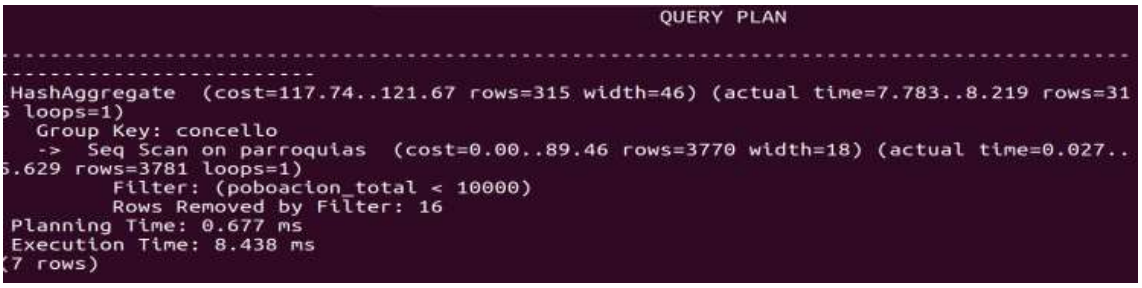

Incluso sacar o índice da táboa orixinal para a busca pode facer a busca na táboa foránea máis rápida, especialmente engadindo un filtro.

Co cstore_fdw, a consulta completase máis rápido porque procesa menos datos: cada columna dividise en varios bloques e os índices de salto almacenan valores mínimos e máximos para cada un destes bloques. Se estes valores contradicesen co WHERE ao escanear a táboa, o bloque omitese por completo.

Podemos ver como elimina uns 16 rexistros na busca e isto é porque o cstore_fdw crea coa opción block_row_count (número de filas por bloques de columna) é dicir, fai bloques de columnas onde almacena o mínimo e o máximo valor e así funciona con bloques de exclusión, onde só busca os bloques onde está a condición WHERE, os outros son ignorados.

Para usar os índices de salto de forma máis eficiente, cargamos os datos despois de ordenalos nunha columna que se usa na cláusula WHERE. Isto garante que haxa unha superposición mínima entre os bloques e que a probabilidade de que se salten sexa maior.

6. Instalacion de la BBDD Adventure Works.

Ofrécese un ficheiro Ruby para converter os CSV dispoñibles en CodePlex nun formato que Postgres poida usar, así como un script de Postgres para crear as táboas, cargar os datos, converter as columnas de identificadores xerárquicos, engadir claves primarias e externas e crear algunhas das vistas. Todo isto gárdase no script OLTP de Adventure Works 2014, que descargamos e descomprimimos.

Engadimos a este cartafol o update_csvs.rb e install.sql. Instalamos os ruby a través da terminal, accedemos ao directorio onde se encontra o update_csvs.rb `cd /tmp/AdventureWorks` e executamos:

```
ruby update_csvs.rb
```

Con este comando, modificamos os CSV para que funcionen con Postgres.

Accedemos ao postgres na terminal e entramos no mesmo directorio mencionado anteriormente, pois ai tamen se encontra o noso ficheiro install.sql. Creamos a base de datos e as táboas, importamos os datos e configuramos as vistas e as claves:

```
psql -c "CREATE DATABASE \"Adventureworks\";"
    psql -d Adventureworks < install.sql
```

Finalmente para observar se está todo correcto podemos executar no psql para conectarse a esta base de datos e ver a lista de táboas:

```
\c "Adventureworks"
\dt (humanresources|person|production|purchasing|sales).*
```

7. Seccions do fichero install.sql e o seu propósito.

O principal propósito de install.sql é ter un ficheiro que cun simple comando na terminal podas crear as táboas, cargar os datos, converter as columnas de identificadores xerárquicos, engadir claves primarias e externas e crear algunhas das vistas. Este podemolo dividir nas seguintes seccions:

1. **Instalacion do AdventureWorks.** Esta primeira sección consiste nunha breve explicación de cómo podemos usar este script: descargar o zip, comandos para crear as táboas,importar os datos, mostrar as táboas**…** Todo esto está comentado a través do --
2. **Creacion de tipos de datos personalizados.** A través do commando `CREATE DOMAIN` creanse 6 datos: *OrderNumber, AccountNumber, Flag, NameStyle,Name* e *Phone.*
3. **Creacion dos esquemas cos seus datos e táboas** a través do commandos `CREATE SCHEMA, CREATE TABLE`
4. **Copiar os datos almacenados nos cvs nas suas correspondientes tablas** a través do commando `SELECT … \copy … FROM ….`
5. **Convertir de todo o hexágono nun fluxo de bits xerárquicos:** `CREATE OR REPLACE FUNCTION`
6. **Comentarios nas táboas e columnas** a través dos comandos `COMMENT ON TABLE…, COMMENT ON COLUMN…`
7. **Establecer as PRIMARY KEYS (chaves primarias) e as FOREIGN KEYS (chaves foráneas)** usando o `ALTER TABLE`
8. **Vistas:** aparece comentado unha consulta en MSSQL para ver a diferencia nas consultas orientadas a XML entre MSSQLServer e Postgres. Finalmente, executa na versión postgres que é mais recortada a través `CREATE VIEW …AS…SELECT e` clasifica os produtos e descripcions destes produtos por idioma formando unha vista materializada para que o rendimento poida ser mellor.
9. **Vistas de conveniencia**. Crea un esquema `CREATE SCHEMA` para varias vistas, agrupándoas.

8. Instalación da base de datos AdventureWorksDW2012.

Accedemos ao postgres na terminal e entramos no directorio `cd /tmp/AdventureWorksDW`, creamos a base de datos e as táboas, importamos os datos e configuamos as vistas e as claves:

```
psql -c "CREATE DATABASE \"AdventureworksDW\";"
psql -d AdventureworksDW < AdventureWorksDW2012.sql
```

Non é posible executar o .sql pois a versión que temos de postgres non admite ben o tipo money $ e os números que o teñan a coma dos millares. Para solucionalo:

- Executamos `nano AdventureWorksDW2012.sql` para editar o arquivo e sustituir o $ por un espacio.
- Executamos o comando sed que permite buscar e remplazar expresions e consiste en:

```
sed 's/texto_a_buscar/texto_a_reemplazar/' <fichero_a_reemplazar
>fichero_nuevo
```

De esta maneira, poñemos na terminal o seguinte:

```
sed –i  ‘s/\([0-9]\),\([0-9]\)/\1\2/g’/tmp/AdventureWorksDW/AdventureWorksDW2012.sql
```

Procedemos a facer consultas na base de datos para comprobar que esta todo correcto:

```
select count(salesterritoryregion) as regions_US
from dimsalesterritory
where salesterritorycountry ='United States'
```

	regions_us bigint
1	4

```
select avg(promotionkey),discountpct, startdate, enddate
from dimpromotion
where discountpct > 0.2
group by discountpct,startdate,enddate
order by discountpct asc
```

	avg numeric	discountpct real	startdate timestamp without time zone	enddate timestamp without time zone
1	6.000000000	0.2	2005-07-01 00:00:00	2008-06-30 00:00:00
2	14.00000000	0.2	2007-07-01 00:00:00	2007-09-30 00:00:00
3	9.000000000	0.3	2006-07-01 00:00:00	2006-08-31 00:00:00
4	7.000000000	0.35	2006-05-15 00:00:00	2006-06-30 00:00:00
5	12.00000000	0.35	2007-07-01 00:00:00	2007-08-15 00:00:00
6	16.00000000	0.4	2008-05-01 00:00:00	2008-06-30 00:00:00
7	10.00000000	0.5	2007-06-15 00:00:00	2007-08-30 00:00:00
8	15.00000000	0.5	2007-08-15 00:00:00	2007-09-15 00:00:00

Finalmente, remataremos comparando a estructura da base de datos de AdventureWorks (apartado anterior) coa AdventureWorksDW (apartado actual):

- AdventureWorksDW ten 68 táboas e AdventureWorks ten 72 táboas. Ten cambios nas táboas debido que a DW ten esquemas para as sales, purchasaing, production, humanResources e person.
- AdventureWorksDW presenta un esquema e a AdventureWorks presenta quinto esquemas diferentes.

A AdventureWorksDW está deseñada para ser máis rápida; concretamente, para proporcionar un acceso rápido á recuperación e análise de datos. Permite un acceso, recompilación e análise de datos máis rápido para que se poida tomar decisións.